

深度学习实验报告二

图像分类——基于 ViT 的 CIFAR10 识别

姓 名：冯明

学 号：202528013229074

课 程：深度学习

所在单位：中国科学院大学

一、概述

本实验要求在 CIFAR10 数据集上完成 10 类图像分类，目标测试准确率不低于 80%。CIFAR10 包含 50,000 张 32×32 RGB 彩色图像，涵盖飞机、汽车、鸟等 10 个类别。本实验从零实现 Vision Transformer (ViT)，不使用任何预训练权重，通过 PatchEmbedding 将图像切分为 patch 序列，经 6 层 Transformer Encoder 建模后输出分类结果。在华为云 Tesla T4 GPU 上训练 50 个 epoch，最终取得测试准确率 80.48%，满足实验要求。

二、解决方案

2.1 网络结构设计

ViT 的核心思想是将图像切分为固定大小的 patch，视为 token 序列送入 Transformer。本实验采用 `patch_size=4`，将 32×32 图像切分为 64 个 4×4 patch，通过步长等于 `patch_size` 的 Conv2d（相当于线性投影）映射为 192 维向量。在序列头部拼接可学习 CLS token，并加入可学习位置嵌入（shape: $1 \times 65 \times 192$ ），然后经过 6 层 Pre-Norm TransformerBlock，取 CLS token 位置输出接线性分类头。

```
# PatchEmbedding
self.proj = nn.Conv2d(3, 192, kernel_size=4, stride=4) # -> (B,192,8,8)
x = self.proj(x).flatten(2).transpose(1, 2)           # -> (B,64,192)

# CLS token & 位置编码
self.cls_token = nn.Parameter(torch.zeros(1, 1, 192))
self.pos_embed = nn.Parameter(torch.zeros(1, 65, 192))
x = torch.cat([cls, x], dim=1) + self.pos_embed

# Pre-Norm TransformerBlock
attn_out, _ = self.attn(self.norm1(x), self.norm1(x), self.norm1(x))
x = x + attn_out
x = x + self.mlp(self.norm2(x))
```

2.2 损失函数与优化器

损失函数：nn.CrossEntropyLoss()。优化器：AdamW（lr=3e-4，weight_decay=0.05）。weight_decay 设置为 0.05（远大于常规的 1e-4），是 ViT 类模型的关键超参——Transformer 参数量大，需更强 L2 正则防止过拟合。学习率调度：CosineAnnealingLR（T_max=50），余弦退火在训练后期能有效抑制 loss 振荡，避免固定学习率导致的收敛不稳定。模型超参：patch_size=4，embed_dim=192，depth=6，num_heads=3，mlp_ratio=4.0，dropout=0.1，总参数量约 3.7M。

三、实验分析

3.1 数据集介绍

CIFAR10 由 Alex Krizhevsky 于 2009 年发布，共 10 类物体，每类各 6,000 张 32×32 RGB 图像。训练集 50,000 张，测试集 10,000 张。数据增强：训练时使用 RandomResizedCrop(32)和 RandomHorizontalFlip，测试时仅做标准化。标准化参数： $\text{mean}=(0.4914,0.4822,0.4465)$ ， $\text{std}=(0.2023,0.1994,0.2010)$ ，与 CIFAR10 全局像素统计一致。从训练集切出 10%（5,000 张）作为验证集。

3.2 实验结果与分析

训练在华为云 Tesla T4 GPU 上完成（2026-05-18），共 50 个 epoch，关键节点指标如下：

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
10	0.9432	66.12%	0.9559	66.48%
20	0.6665	76.32%	0.6877	76.62%
30	0.4679	83.09%	0.6188	79.60%
36	0.3786	86.45%	0.6257	80.00%（首次突破 80%）
44	0.2991	89.18%	0.6361	80.52%（最优验证）
50	0.2828	89.95%	0.6366	80.46%

最终测试集：test_acc = 80.48%，test_loss = 0.6531，满足≥80%目标。




图2 实验二训练过程：损失曲线（左）与准确率曲线（右），红点标注最优验证点(ep44, 80.52%)

从训练曲线可以观察到，ViT 从零训练收敛较慢，前 10 个 epoch 验证准确率仅约 66%。这是因为 Transformer 缺乏 CNN 的归纳偏置（平移不变性、局部感受野），需要更多数据和轮次才能学到有效的空间特征表示。模型在第 36 个 epoch 首次突破 80%，第 44 个 epoch 达到最优验证准确率 80.52%。CosineAnnealingLR 的作用在后半段训练中尤为明显——验证 loss 在第 30-50 epoch 之间几乎不再上升，说明

余弦退火有效防止了过拟合加剧。对比实验：将 `weight_decay` 降至 0.01 时最终验证准确率约 78.2%（低 2.3%），印证了大 `weight_decay` 对 ViT 泛化的重要性。

四、总结

本实验从零实现了完整的 ViT，包含 PatchEmbedding、CLS Token、可学习位置编码和 Pre-Norm TransformerBlock，经 50 个 epoch 训练在 CIFAR10 上达到 80.48% 测试准确率，满足实验要求。ViT 的优势在于全局注意力机制能够捕捉图像中任意位置间的依赖关系，但代价是对训练数据量和训练轮次要求较高。Pre-Norm + 残差结构保证了 6 层深度网络训练的稳定性；AdamW 的强正则配合 CosineAnnealingLR 是从零训练 ViT 达标的组合。后续改进方向：使用 DeiT 或 MAE 预训练权重进行微调（同等模型可达 95%+），或引入 Mixup/CutMix 数据增强进一步提升泛化能力。