

大数据安全课程大作业实验报告

选项二：差分隐私算法实现

姓 名：冯明

学 号：202528013229074

课 程：大数据安全

所在单位：中国科学院大学

一、实验目标

本实验选择大作业选项二，围绕差分隐私（Differential Privacy，DP）与联邦学习（Federated Learning，FL）的结合展开，具体目标包括以下几个方面：

- （1）掌握联邦学习和差分隐私的基本原理，理解二者结合的必要性与实际意义；
- （2）了解联邦学习算法（FedAvg）的完整工作流程，包括本地训练、梯度上传与全局聚合；
- （3）掌握在联邦学习中应用差分隐私的具体方法，分别实现拉普拉斯机制和高斯机制；
- （4）通过复现 GRNN 梯度攻击并结合差分隐私防护实验，直观理解差分隐私技术的保护效果与局限性。

二、实验方案与参数设置

2.1 联邦学习框架

实验采用经典的 FedAvg（Federated Averaging）算法模拟联邦学习场景。全局模型由服务器维护，每轮通信中各客户端基于本地数据独立训练，再将参数更新（ Δw ）上传服务器进行平均聚合。数据集采用 MNIST 手写数字识别数据集（60,000 训练样本，10,000 测试样本），按 IID（独立同分布）方式均分给 10 个客户端，每个客户端持有约 6,000 条数据。模型统一使用 LeNet（双卷积块 CNN，约 60K 参数）。实验在搭载 Tesla T4 GPU 的服务器上运行，全程训练耗时约 2 小时。

主要超参数如下表所示：

参数	取值	说明
客户端数量 K	10	均分 MNIST 训练集，IID 划分
通信轮数 T	100	服务器与所有客户端共迭代 100 轮
本地训练轮次	1 epoch	每轮客户端在本地数据上跑 1 个 epoch
本地批大小	64	SGD，momentum=0.5，lr=0.01
梯度裁剪范数 C	1.0	全局 L2 灵敏度，对客户端更新裁剪
高斯机制 δ	1e-5	(ϵ, δ) -差分隐私中的失败概率

2.2 差分隐私噪声机制

为保护各客户端的本地训练数据，在将梯度更新上传服务器前，先进行裁剪再加入噪声。具体流程为：①计算本地更新 $\Delta w = w_{\text{local}} - w_{\text{global}}$ ；②按 L2 范数对 Δw 进行裁剪（clip by norm $C=1.0$ ）；③向裁剪后的更新加入 DP 噪声后上传。

本实验实现了两种噪声机制：

拉普拉斯机制（ ϵ -DP）：噪声尺度参数 $b = C / \epsilon$ ，对每个参数分量独立采样 $\text{Laplace}(0, b)$ ，提供纯差分隐私（pure DP）保证。 ϵ 越小，加入的噪声越大，隐私保护越强。

高斯机制（ (ϵ, δ) -DP）：噪声标准差 $\sigma = C \cdot \sqrt{(2 \cdot \ln(1.25/\delta))} / \epsilon$ ，对每个参数分量独立采样 $N(0, \sigma^2)$ ，提供近似差分隐私保证（ $\delta=1e-5$ ）。相比拉普拉斯机制，高斯噪声分布更集中，但在相同 ϵ 下噪声规模通常更大。

```
# 拉普拉斯机制：b = C / ε
noise = Laplace(0, C/ε).sample(param.shape)

# 高斯机制：σ = C × sqrt(2 × ln(1.25/δ)) / ε, δ=1e-5
sigma = C * sqrt(2 * log(1.25 / 1e-5)) / epsilon # ≈ C × 4.84 / ε
noise = Normal(0, sigma).sample(param.shape)
```

各机制对应的每轮隐私预算 ϵ 设置如下：

机制	每轮 ϵ 值	对应总体 ϵ_{total} (T=100 轮)
拉普拉斯 (ϵ -DP)	10, 25, 50, 75, 100, $+\infty$	1000, 2500, 5000, 7500, 10000, $+\infty$
高斯 ((ϵ, δ) -DP)	1, 5, 10, 20, 30, $+\infty$	100, 500, 1000, 2000, 3000, $+\infty$

三、多轮联邦学习的隐私预算分析

在联邦学习中，每轮训练都会消耗一定的隐私预算。根据差分隐私的简单组合定理（Simple Composition Theorem）：若每轮使用 ϵ -DP 机制保护，则经过 T 轮后，整个训练过程对单个客户端数据的总体隐私保证退化为 $T \cdot \epsilon$ -DP，即：

```
ε_total = T × ε_per_round

# 本实验 T=100，各设置的总体隐私预算为：
# 拉普拉斯，ε/轮=10 → ε_total = 100 × 10 = 1000
# 拉普拉斯，ε/轮=25 → ε_total = 100 × 25 = 2500
# 高斯，ε/轮=1 → ε_total = 100 × 1 = 100
# 高斯，ε/轮=30 → ε_total = 100 × 30 = 3000
```

简单组合定理给出的是最坏情况下的上界，实际上隐私损耗可能更小。工程实践中通常配合矩会计（Moments Accountant）或 Rényi 差分隐私（RDP）等更紧的分析方法来减少预算消耗、提升模型效用，各设置的隐私预算汇总如下表：

机制	每轮 ϵ	总预算 ϵ_{total}	噪声标准差/尺度	隐私强度
拉普拉斯	10	1,000	$b = 0.10$	强
拉普拉斯	25	2,500	$b = 0.04$	中
拉普拉斯	50	5,000	$b = 0.02$	较弱
拉普拉斯	100	10,000	$b = 0.01$	弱
高斯	1	100	$\sigma \approx 4.84$	极强
高斯	5	500	$\sigma \approx 0.97$	强
高斯	10	1,000	$\sigma \approx 0.48$	较强

高斯	30	3,000	$\sigma \approx 0.16$	弱
----	----	-------	-----------------------	---

可以看出，高斯机制在相同 ϵ 下噪声标准差远大于拉普拉斯机制的尺度参数，这是因为高斯机制需要额外的 δ 来放松隐私定义，换来了更好的数值性质，但在小 ϵ 场景下噪声代价极为显著，这在后续实验结果中得到了印证。

四、实验运行过程

实验代码在配备 Tesla T4 GPU（16GB 显存）的云服务器上运行，操作系统为 Ubuntu 20.04，PyTorch 版本 2.2.2（CUDA 12.1）。以下为训练过程中的终端输出（部分节选）：

```
root@gpu-server:/tmp/dp_exp# python3 -u fl_dp.py
Device: cuda | N_CLIENTS=10 N_ROUNDS=100

=== Laplace Mechanism ===

 $\epsilon$  = 10.0
Round 1/100  $\epsilon$ =10.0 acc=0.0930
Round 10/100  $\epsilon$ =10.0 acc=0.5028
Round 20/100  $\epsilon$ =10.0 acc=0.7457
Round 50/100  $\epsilon$ =10.0 acc=0.7340
Round 100/100  $\epsilon$ =10.0 acc=0.7829
 $\epsilon$  = 25.0
Round 1/100  $\epsilon$ =25.0 acc=0.1088
Round 50/100  $\epsilon$ =25.0 acc=0.9281
Round 100/100  $\epsilon$ =25.0 acc=0.9418
 $\epsilon$  = 50.0
Round 100/100  $\epsilon$ =50.0 acc=0.9687
 $\epsilon$  = 75.0
Round 100/100  $\epsilon$ =75.0 acc=0.9757
 $\epsilon$  = 100.0
Round 100/100  $\epsilon$ =100.0 acc=0.9778
 $\epsilon$  = inf
Round 100/100  $\epsilon$ =inf acc=0.9799
Saved: results/laplace_accuracy.png

=== Gaussian Mechanism ===

 $\epsilon$  = 1.0
Round 100/100  $\epsilon$ =1.0 acc=0.0980
 $\epsilon$  = 5.0
Round 100/100  $\epsilon$ =5.0 acc=0.0980
 $\epsilon$  = 10.0
Round 100/100  $\epsilon$ =10.0 acc=0.0980
 $\epsilon$  = 20.0
Round 100/100  $\epsilon$ =20.0 acc=0.0975
 $\epsilon$  = 30.0
Round 50/100  $\epsilon$ =30.0 acc=0.5960
Round 100/100  $\epsilon$ =30.0 acc=0.4340
 $\epsilon$  = inf
Round 100/100  $\epsilon$ =inf acc=0.9797
Saved: results/gaussian_accuracy.png
```

=== Final Accuracy (Round 100) ===			
ϵ	Laplace	Gaussian	
10.0	78.29%	1.0	9.80%
25.0	94.18%	5.0	9.80%
50.0	96.87%	10.0	9.80%
75.0	97.57%	20.0	9.75%
100.0	97.78%	30.0	43.40%
inf	97.99%	inf	97.97%

五、不同总体隐私预算对联邦学习性能的影响

5.1 拉普拉斯机制实验结果

图 1 展示了在不同总体隐私预算 ($\epsilon_{total} = 100 \times \epsilon/\text{轮}$) 下，拉普拉斯机制对联邦学习测试准确率的影响。




图 1 拉普拉斯机制：不同总体隐私预算下 100 轮联邦学习的测试准确率曲线

从图中可以看到几个比较明显的规律。首先，无噪声基线 ($\epsilon_{total}=+\infty$) 100 轮后准确率达到 97.99%，收敛相对平稳。加入拉普拉斯噪声后， $\epsilon_{total}=1000$ （每轮 $\epsilon=10$ ）时性能下降最为明显，100 轮后准确率仅 78.3%，且收敛过程存在明显波动，说明较大的噪声对梯度聚合干扰很大。随着 ϵ_{total} 增大，曲线逐渐向基线靠拢： $\epsilon_{total}=2500$ 时约 94.2%， $\epsilon_{total}=5000$ 时约 96.9%， $\epsilon_{total} \geq 7500$ 时与基线差距已在 0.5% 以内。这说明拉普拉斯机制在 $\epsilon_{total} \geq 5000$ （每轮 $\epsilon \geq 50$ ）时，对模型性能的影响已较为有限，能在一定程度上实现隐私保护与精度的平衡。

值得注意的是，各曲线在前 20 轮的收敛速度差异较大。 $\epsilon_{total}=1000$ 的情况下，模型在 20 轮时才勉强超过 74%，而 $\epsilon_{total} \geq 5000$ 的配置在 10 轮内就已接近最终精度的 90%。这提示在实际部署中，如果对收敛速度有要求，需要适当放宽隐私约束。

5.2 高斯机制实验结果

高斯机制的实验结果如图 2 所示，其表现与拉普拉斯机制有明显差异。




图2 高斯机制：不同总体隐私预算下 100 轮联邦学习的测试准确率曲线

实验结果出乎意料地严苛。当 $\epsilon_{total} \leq 2000$ （每轮 $\epsilon \leq 20$ ）时，模型 100 轮后准确率始终徘徊在 9.8% 左右，与随机猜测无异。具体来看，当每轮 $\epsilon=10$ 时，高斯噪声标准差 $\sigma \approx 0.48$ ，已经足以完全掩盖客户端的梯度更新，梯度信号完全被淹没，模型根本无法学习。 $\epsilon_{total}=3000$ （每轮 $\epsilon=30$ ， $\sigma \approx 0.16$ ）时模型开始出现学习迹象，但准确率在 40% ~ 70% 之间大幅波动，最终停在 43.4%，仍然很不稳定。只有完全不加噪声（ $\epsilon=+\infty$ ）时，模型才能正常收敛到 97.97%。

造成这一现象的根本原因在于，高斯机制在相同每轮 ϵ 下的噪声规模远大于拉普拉斯机制。以每轮 $\epsilon=10$ 为例：拉普拉斯机制的噪声尺度 $b=0.1$ ，而高斯机制的标准差 $\sigma \approx 0.48$ ，后者约是前者的 5 倍。在本实验的参数配置下（梯度裁剪范数 $C=1.0$ ，批大小 64），客户端梯度更新幅度较小，无法对抗如此量级的高斯扰动。这说明在实际应用高斯机制时，需要结合矩会计等更精细的隐私分析方法，同时适当调整裁剪范数和批大小，才能在强隐私保护下维持可用的模型性能。

六、GRNN 梯度攻击复现与差分隐私防护效果

6.1 攻击原理

GRNN（Gradient Inversion Attack）源自 Zhu et al. 2019 年发表于 NeurIPS 的论文《Deep Leakage from Gradients》（DLG）。其核心思想是：在联邦学习中，攻击者

（通常是恶意的服务器端）能够拿到客户端上传的梯度，而该梯度由真实数据(x_r, y_r)产生。攻击者通过最小化以下目标函数，从梯度反推出原始训练数据：

目标函数：

$$\min_{\{x_d, y_d\}} \sum_l ||\nabla_w L(x_d, y_d; w)_l - \nabla_w L(x_r, y_r; w)_l||^2_F$$

其中 x_d, y_d 是攻击者初始化的随机虚假输入，

1 遍历所有网络层， w 为当前全局模型参数（攻击者已知）。

通过对 x_d, y_d 做梯度下降，使虚假梯度逼近真实梯度，

最终 x_d 收敛到接近原始图像的结果。

本实验使用两层全连接网络（784→128→ReLU→10，参数量约 10 万）复现攻击，优化器为 Adam（lr=0.1），迭代 100 步，配合 torch.autograd.grad 实现二阶梯度计算。

6.2 无差分隐私保护时的攻击效果

在完全不加任何差分隐私噪声的情况下（ $\epsilon_{total}=+\infty$ ），攻击者可以从上传的梯度中几乎完美地重建原始训练图像。图 3 和图 4 分别展示了对数字 8 和数字 3 的重建过程。




图 3 GRNN 攻击重建过程 (label=8, $\epsilon_{total}=+\infty$, 无 DP 保护)
最左为原始图像，其余依次为迭代 5、10、20、40、60、80、100 步的重建结果




图 4 GRNN 攻击重建过程 (label=3, $\epsilon_{total}=+\infty$, 无 DP 保护)

从重建过程可以看出，随机初始化的虚假图像在迭代 20 步左右便开始显现出数字的轮廓，到 80~100 步时已与原始图像高度相似，能够清晰辨认出数字类别。这说明在无 DP 保护的联邦学习中，客户端数据面临严重的隐私泄露风险，即便是经过模型的一次梯度计算，原始数据仍然可以被高精度还原。

6.3 差分隐私对抗 GRNN 攻击的防护效果

为验证差分隐私的防护效果，对同一张数字 8 的图像施加不同强度的高斯机制噪声后，再执行 GRNN 攻击，对比重建质量。图 5 展示了在不同总体隐私预算下的攻击结果：




图5 差分隐私对GRNN攻击的防护效果对比（高斯机制，不同 ϵ_{total} ）

防护效果的定量分析通过重建 MSE（均方误差）衡量，MSE 越大说明重建失真越严重，即攻击越不成功。实验测量结果如下表所示：

隐私配置（高斯）	每轮 ϵ	总体 ϵ_{total}	重建质量	重建 MSE
无保护	$+\infty$	$+\infty$	清晰可辨，攻击成功	0.0033
弱保护	30	3000	轮廓轻微模糊	0.0172
中等保护	10	1000	基本不可辨认	0.3206
较强保护	5	500	近似随机噪声	0.3184
强保护	1	100	完全随机，攻击失效	0.4014

从图 5 和上表可以得出以下结论：无 DP 保护时（ $\epsilon_{total}=+\infty$ ），重建 MSE 仅 0.0033，攻击效果极佳；当总体预算降至 $\epsilon_{total}=3000$ 时，MSE 上升到 0.017，已能看出噪声影响； $\epsilon_{total}\leq 1000$ 时，MSE 突增至 0.32 ~ 0.40，重建图像与原始图像几乎没有视觉相似性，攻击宣告失败。这说明差分隐私在 $\epsilon_{total}\leq 1000$ 的强度下能够有效阻断 GRNN 梯度攻击，保护客户端数据隐私。当然，这也对应着前面联邦学习实验中模型精度的显著损失，再次体现了隐私与效用之间的基本矛盾。

七、总结

本实验完整实现了基于差分隐私的联邦学习系统，并通过 GRNN 梯度攻击的复现直观验证了差分隐私的实际保护效果，主要得出以下几点认识：

第一，精度-隐私权衡是差分隐私联邦学习的核心矛盾。隐私预算越小，噪声越大，模型精度越低。拉普拉斯机制在 $\epsilon_{total}=5000$ （每轮 $\epsilon=50$ ）时仍能维持约 97% 的精度，隐私-效用权衡相对合理；高斯机制在本实验配置下对小 ϵ 极为敏感， $\epsilon_{total}\leq 2000$ 时模型完全失效，需要结合更精细的隐私分析方法才能实用。

第二，简单组合定理给出的是隐私损耗的上界，实际损耗往往更小。100 轮训练后总体隐私预算按简单组合定理为 $100\times\epsilon$ ，实践中使用矩会计可将这一上界收紧数倍，从而在相同轮数下维持更强的隐私保证。

第三，GRNN 攻击实验直观展示了梯度中包含的隐私信息之丰富。在无 DP 保护下，仅凭一次梯度上传，攻击者便能以极低误差重建原始训练图像。差分隐私有效阻

断了这一攻击路径，在 $\epsilon_{\text{total}} \leq 1000$ 时重建 MSE 提升 100 倍以上，彻底使攻击失效，验证了差分隐私作为梯度保护手段的有效性。